나비 LLM의 족보

나비의 AI는 어떤 방식으로 일하고, 그 뿌리는 어디에서 왔을까요?

> 한 줄 요약: 나비는 분야마다 따로 훈련한 작은 AI 여러 개를 두고, 질문에 맞는 하나만 불러 씁니다. 이 AI들의 뿌리를 거슬러 올라가면 한국, 중국, 미국을 거쳐 캐나다 토론토 대학의 연구까지 이어집니다.

나비의 AI는 어떻게 일하나요?

챗GPT 같은 거대한 AI는 한 명의 만물박사가 모든 분야의 모든 질문에 답하는 것과 같습니다. 질문이 하나 들어올 때마다 큰 AI 전체가 일을 합니다.

나비는 병원에 가까운 방식입니다. 접수 창구에서 증상을 듣고 알맞은 전문의를 연결하듯이, 이렇게 일합니다.

1. SK텔레콤이 만든 한국어 AI **A.X 4.0**을 법률, 의료, 세무 같은 **수백 개 전문 분야별로 추가 훈련**합니다. 이것을 파인튜닝이라고 합니다. 각 AI는 자기 분야의 지식만 갖춘 작은 AI가 됩니다.
2. 나비웹 사용자가 무언가를 부탁하면, 나비가 그 뜻을 파악해서 **가장 알맞은 분야의 AI 하나만** 불러 일을 시킵니다.
3. 나머지 수백 개의 AI는 쉬고 있습니다. 필요한 AI만 일하므로 컴퓨터 자원을 아끼는 것이 이 방식의 설계 의도입니다. 나비 소개 자료는 이 방식을 **MoTE(분야별 전문가 AI 혼합)**라고 부릅니다.

	거대 범용 AI	나비
비유	만물박사 한 명	분야별 전문의 수백 명과 접수 창구
지식	거의 모든 분야를 한 AI에	분야마다 따로 훈련한 작은 AI
질문이 들어오면	큰 AI 전체가 일함	알맞은 작은 AI 하나만 일함

법령이 바뀌면 해당 분야 AI만 다시 훈련하고, 분야별로 성능을 따로 점검할 수 있다는 장점도 기대하고 있습니다. 다만 이것은 설계에서 기대하는 점이고, 아직 측정한 결과는 아닙니다.

지금은 어떤 AI를 쓰고, 앞으로는요?

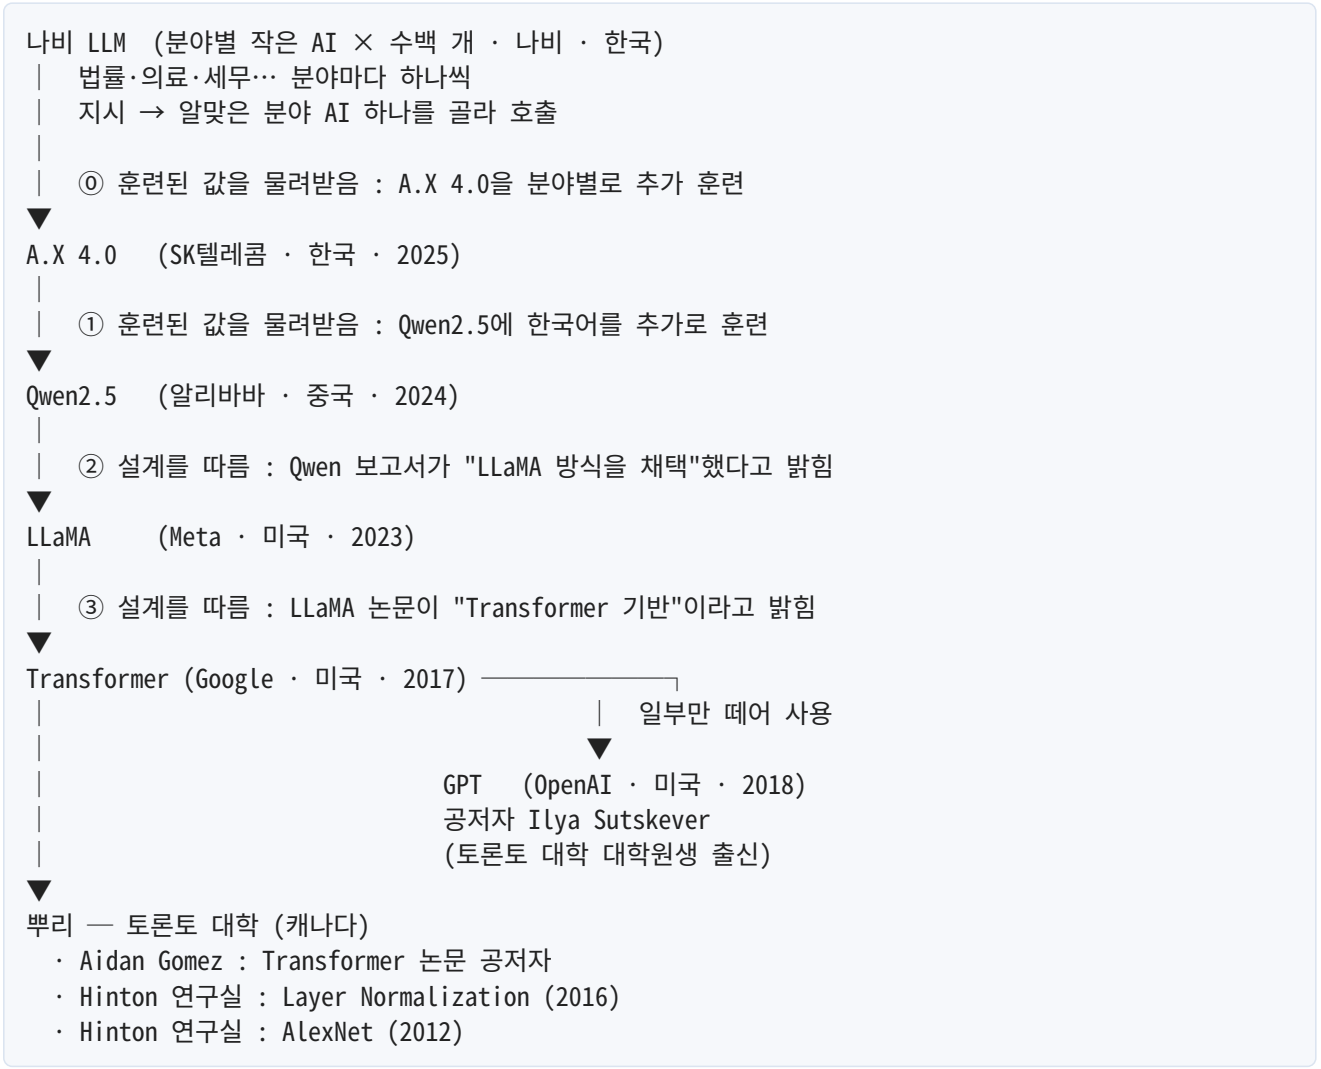
나비는 두 단계로 나누어 AI를 씁니다.

단계	어떤 때인가요	쓰는 AI
웹앱 단계 (최종 필드 테스트)	지금	중국 DeepSeek의 공식 API
상용화 단계	안드로이드·아이폰 앱으로 정식 출시할 때	**나비 LLM** (A.X 4.0을 분야별로 훈련한 AI)

DeepSeek 공식 API는 **웹앱 단계, 즉 최종 필드 테스트 단계까지만** 이용합니다. 실제 안드로이드와 아이폰 앱으로 나비를 상용화하는 단계에서는 나비 LLM을 적용합니다.

필드 테스트 단계에서는 질문이 외부 업체(DeepSeek)의 서버로 전달됩니다. 이 단계에서는 주민등록번호나 건강·재산 정보 같은 민감한 개인정보를 입력하지 않는 것이 좋습니다.

나비 LLM의 족보



족보는 두 종류입니다

- **훈련된 값의 계보**: AI가 훈련으로 얻은 지식을 실제로 물려받은 관계입니다. 나비 LLM ← A.X 4.0 ← Qwen2.5까지가 여기에 해당합니다. Qwen은 LLaMA의 훈련된 값을 물려받은 것이 아니라 자체 데이터로 훈련했습니다.
- **설계의 계보**: AI의 구조와 기법을 따온 관계입니다. Qwen ← LLaMA ← Transformer를 거쳐 토론토까지 이어집니다. 논문에 "따랐다"고 적힌 영향 관계이고, 코드나 훈련된 값을 복사했다는 뜻이 아닙니다.

세대별로 보면

모델 (연도)	만든 곳	물려받은 것
나비 LLM	나비 (한국)	A.X 4.0을 분야별 자료로 추가 훈련
A.X 4.0 (2025)	SK텔레콤 (한국)	Qwen2.5에 한국어 토크나이저 교체, 한국어 추가 훈련, 미세조정, 강화학습을 더함
Qwen2.5 (2024)	알리바바 (중국)	Transformer 구조에 GQA, SwiGLU, RoPE, RMSNorm 등 기법. 18조 토큰으로 훈련
Qwen 1세대 (2023)	알리바바 (중국)	"LLaMA를 채택"했다고 밝힘
LLaMA (2023)	Meta (미국)	Transformer 기반. GPT-3, PaLM 등의 기법을 가져옴
Transformer (2017)	Google (미국)	어텐션만으로 만든 구조
GPT (2018)	OpenAI (미국)	Transformer에 "대량 훈련 후 미세조정" 방식을 얹음

토론토 대학으로 닿는 길

연결	내용
Transformer 공저자	Aidan Gomez는 논문에 소속을 토론토 대학으로 적었고, 이후 AI 기업 Cohere를 공동 창업했습니다.
Layer Normalization (2016)	토론토 대학 Hinton 연구실의 논문입니다. Qwen 보고서가 "이 방식을 RMSNorm으로 바꿨다"고 밝혔을 만큼 직접 연결됩니다.
GPT와 Sutskever	GPT 논문 공저자 Ilya Sutskever는 Hinton의 대학원생으로 토론토 대학에서 연구했습니다.
BooksCorpus	GPT 1세대가 훈련에 쓴 책 말뭉치는 "Toronto Book Corpus"라고도 불립니다.
AlexNet (2012)	토론토 대학에서 만든 신경망으로, 딥러닝 시대를 연 계기가 됐습니다. Hinton은 2024년 노벨 물리학상을 받았습니다.

이 족보가 말해 주는 것

- **뿌리에는 국경이 없습니다.** 오늘날 AI의 설계 요소는 미국, 캐나다, 중국, 영국 등 여러 곳의 연구에서 왔고, 모두 논문으로 공개됐습니다.
- **"국내 개발"은 층을 나눠 말해야 정확합니다.** 나비 LLM이 물려받은 훈련된 값은 A.X 4.0을 거쳐 중국

알리바바의 공개 모델에서 이어지고, 그 위에 한국이 한국어와 분야별 훈련을 더한 것입니다. 설계의 뿌리까지 한국이 새로 만든 것은 아닙니다.

- **나비는 한 뿌리에서 갈라진 수백 개의 AI 중 필요한 하나만 씁니다.** 분야마다 따로 훈련하기 때문에, 하나의 거대한 AI가 아니라 같은 조상을 둔 형제 AI들이 팀으로 일하는 구조입니다.

알아 두면 좋은 점

- **분야를 가르는 일이 중요합니다.** 질문이 두 분야에 걸치거나 분야를 잘못 고르면 엉뚱한 AI가 불릴 수 있습니다. 어떤 AI를 부르느냐가 전체 품질을 좌우합니다.
- **거대 AI도 자원을 나눠 씁니다.** 상용 서비스도 질문의 난이도에 따라 작은 모델과 큰 모델을 바꿔 쓰거나, 모델 안에서 일부만 작동시키는 경우가 있습니다. 나비의 차이는 분야 단위로 독립된 AI를 두고 따로 훈련하고 점검한다는 점에 있습니다.
- **이 글이 다루지 않은 것**: 나비 LLM의 구체적인 크기와 훈련 방식, Qwen 1세대와 Qwen2.5 사이 중간 버전의 세부 내용, 어텐션 개념의 원조로 알려진 몬트리올 대학 쪽 연구는 확인하지 않았습니다.

근거 자료

- A.X 4.0 (SKT-AI GitHub)
- Qwen2.5 Technical Report
- Qwen Technical Report
- LLaMA: Open and Efficient Foundation Language Models
- Attention Is All You Need
- Layer Normalization
- Improving Language Understanding by Generative Pre-Training (OpenAI, 2018)
- OpenAI GPT 모델 문서 (Hugging Face)
- AlexNet과 Hinton의 노벨상 (토론토 대학)

문의: 나비 개발자 대표 도영민 · hondi.net